

大数据技术基础课程实验报告

实验四: Spark Core Scala、Spark SQL

付容天

学号 2020211616

班级 2020211310

计算机学院(国家示范性软件学院)

1. 实验描述与实验目的

本实验使用 Scala 语言编写 Spark 程序,完成单词计数任务、独立应用程序实现数据去重任务,并使用 Spark SQL 完成数据库读写任务。实验分为三个部分:首先,在华为云购买 4 台服务器(已完成),然后搭建 Hadoop 集群和 Spark 集群(YARN 模式)(已完成),接着使用 Scala 语言利用 Spark Core 编写程序,最后将程序打包在集群上运行;其次,使用 Scala 语言编写独立应用程序实现数据去重,并将程序打包在集群上运行;最后,使用 Spark SQL 读写数据库,包括在服务器上安装 MySQL 和通过 JDBC 连接数据库在本次实验中,我们需要在实验一、二搭建完毕的集群环境上,继续安装 HBase、ZooKeeper,并实践 HBase 的基本使用。

本次实验的目的是:

- (1) 了解服务器配置的过程;
- (2) 熟悉使用 Scala 编写 Spark 程序;
- (3) 了解 Spark RDD 的工作原理;
- (4) 掌握在 Spark 集群上运行程序的方法;
- (5) 掌握使用 Spark SQL 读写数据库的方法。

2. 实验过程与实验分析

2.1. Spark Core Scala 单词计数

这部分的实验中,我首先按照实验指导书要求启动了 Hadoop 集群,并通过 jps 和 ifconfig 两条指令进行了必要的检查,结果如下所示:

图 1: node1 状态检查 (对应指导书图 1) 图 2: node2 状态检查 (对应指导书图 2)

图 3: node3 状态检查(对应指导书图 3) 图 4: node4 状态检查(对应指导书图 4)

通过以上四幅图,可以看到在 node1 上有四个进程(ResourceManager、SecondaryNameNode、NameNode、JPS),在 node2 到 node4 上均为三个进程(JPS、NodeManager、DataNode)。我们还可以发现 node1 到 node4 的 IP 地址分别为 192. 168. 0. 34、192. 168. 0. 41、192. 168. 0. 167 和 192. 168. 0. 114。

紧接着我按照实验指导书内容执行了相应命令(该测试命令用以计算圆周率 PI),测试 Hadoop 集群的可用性,结果如下图 5 和 6 所示:

```
out@frt-2020211616-0001:~
[root@frt-2020211616-0001 hadoop-2.7.7]# cd ~
[root@frt-2020211616-0001 ~]# hadoop jar ../home/modul
7.7. jar pi 10 1
Number of Maps = 10
Samples per Map = 1
23/04/16 16:11:38 WARN util.NativeCodeLoader: Unable
va classes where applicable
Wrote input for Map #0
Wrote input for
                   Map #1
Wrote input for Map #2
Wrote input for Map #3
Wrote input for Map #4
Wrote input
              for
                   Map #5
Wrote input for
                   Map #6
Wrote input for
                   Map #7
Wrote input for Map #8
Wrote input for Map #9
Starting Job
23/04/16 16:11
                 .30 TMF0
```

图 5: Hadoop 集群可用性测试 (对应指导书图 5)

图 6: Hadoop 集群可用性测试 (对应指导书图 6)

在确定 Hadoop 集群可用之后,我向主节点(即 node1)节点上传、解压 Spark 安装包,并进行必要的配置(修改. bash_profile 文件和 yarn-site. xml 文件)。然后使用 scp 命令将修改后的 yarn-site. xml 文件发送到三个从节点。此时重启 Hadoop 服务,查看 JPS 可以发现与图 1-图 4 所示结果一致,运行 Spark 中提供的计算圆周率 PI 的指令,得到图下图 7 所示的结果,可以确定此时 Spark 集群部署成功!

```
23/04/16 16:25:54 INFO scheduler. TaskSetManager: Starting task 8.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 5.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 6.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 8.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Starting task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 8.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 7.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 2.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetManager: Finished task 9.0 in stage 23/04/16 16:25:54 INFO scheduler. TaskSetMan
```

图 7: 检验 Spark 集群搭建成功 (对应指导书图 7)

之后运行 spark-shell 命令,可以看到 Spark 和 Scala 版本信息:

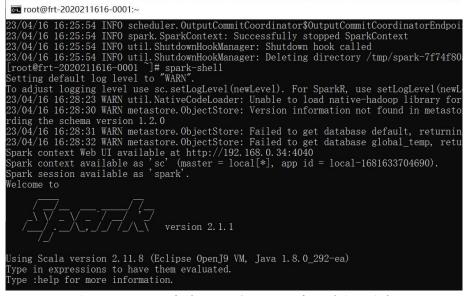


图 8: 进入 spark-shell 查看 Spark 和 Scala 版本 (对应指导书图 8)

接下来的任务就是在 IDEA 中创建项目,完成代码编写并进行配置,之后生成 jar 包。该阶段中我主要完成了:

- (1) 工程创建,命名为 spark-test,选择正确的 archetype;
- (2) 根据指导书内容修改 pro. xml 配置文件,并使之生效;
- (3) 设置语言环境和 java Compiler 环境;
- (4) 删除模板中 test 文件夹下的测试类 (即 AppTest 和 MySpec 两个文件);

- (5) 创建 Scala Class,命名为 ScalaWordCount,并编写相应的代码;
- (6) 设置 Project Settings 中的 Artifacts,选择好主类;
- (7) 选择 Build->Artifacts, 生成 jar 包;
- (8) 删除 jar 包中 META-INF 目录下的 MANIFAST. MF 文件。

接下来将 jar 包传到 node1 上,并通过 spark-submit 命令执行程序,得到如下图 9 所示的结果:

```
23/04/16 16:30:11 INFO storage.BlockManagerInfo: Added broadcast_3_piece0 in memory on node2:42037 (23/04/16 16:30:11 INFO storage.BlockManagerInfo: Added broadcast_3_piece0 in memory on node4:45277 (23/04/16 16:30:11 INFO spark.MapOutputTrackerMasterEndpoint: Asked to send map output locations for 23/04/16 16:30:11 INFO spark.MapOutputTrackerMaster: Size of output statuses for shuffle 1 is 172 by 23/04/16 16:30:11 INFO spark.MapOutputTrackerMasterEndpoint: Asked to send map output locations for 23/04/16 16:30:11 INFO spark.MapOutputTrackerMasterEndpoint: Asked to send map output locations for 23/04/16 16:30:11 INFO scheduler.TaskSetManager: Starting task 2.0 in stage 4.0 (TID 11, node2, exec 23/04/16 16:30:11 INFO scheduler.TaskSetManager: Finished task 1.0 in stage 4.0 (TID 10) in 65 ms on 23/04/16 16:30:11 INFO scheduler.TaskSetManager: Finished task 0.0 in stage 4.0 (TID 9) in 84 ms on 23/04/16 16:30:11 INFO scheduler.TaskSetManager: Finished task 2.0 in stage 4.0 (TID 11) in 35 ms on 23/04/16 16:30:11 INFO cluster, YarnScheduler: Removed TaskSet 4.0, whose tasks have all completed, for 23/04/16 16:30:11 INFO scheduler.DAGScheduler: ResultStage 4 (collect at ScalaWordCount.scala:21) fit 23/04/16 16:30:11 INFO scheduler.DAGScheduler: Job 1 finished: collect at ScalaWordCount.scala:21, the (hi, 6), (hello, 5), (spark, 2), (sparkStreaming, 1), (sparkgrapnx, 1), (sparksq1, 1)23/04/16 16:30:11 INFO Configuration, deprecation: mapred.task.id is deprecated. Instead. use mapreduce
```

图 9: spark-submit 命令执行结果 (对应指导书图 46)

查看程序输出,如下图10(画红线处)所示:

```
on root@frt-2020211616-0001:~
[root@frt-2020211616-0001 ~]# hadoop fs -ls /
23/04/16 16:44:36 WARN util.NativeCodeLoader: Unable to load native-hadoop library
Found 7 items
                                                     0 2023-04-03 09:30 /HBase
drwxr-xr-x
                                                    65 2023-03-06 19:18 /frt_2020211616.txt
0 2023-04-16 16:44 /spark-test
                3 root supergroup
drwxr-xr-x
                   root supergroup
drwxr-xr-x
                   root supergroup
                                                     0 2023-04-16 16:28 /tmp
                   root supergroup
drwx-
                                                    65 2023-03-06 19:18 /upload_2020211616.txt
0 2023-04-16 16:11 /user
                3 root supergroup
                         supergroup
      -xr-x
                   root
```

图 10: 程序执行输出(对应指导书图 47)

查看具体的输出内容,如下图 11 所示:

```
[root@frt-2020211616-0001~]# hadoop fs -cat /spark-test/part-00000 23/04/16 16:46:41 WARN util. NativeCodeLoader: Unable to load native(hi, 6) (hello, 5) [root@frt-2020211616-0001~]# hadoop fs -cat /spark-test/part-00001 23/04/16 16:46:46 WARN util. NativeCodeLoader: Unable to load native(spark, 2) [root@frt-2020211616-0001~]# hadoop fs -cat /spark-test/part-00002 23/04/16 16:46:49 WARN util. NativeCodeLoader: Unable to load native(sparksql, 1) (sparkstreaming, 1) (sparkstreaming, 1) (sparkstreaming, 1)
```

图 11: 具体输出内容(对应指导书图 48)

2. 2. RDD 编程:编写独立应用程序实现数据去重

在这部分实验中,我需要编写代码,完成对如下图 12 和 13 所示的两个 txt 文件中数据的合并操作。



```
参考指导书内容,我编写了下面的代码用以完成目标功能:
package org.example
import org.apache.spark.rdd.RDD
import org.apache.spark.{SparkConf, SparkContext}
class ScalaWordMerge{
object ScalaWordMerge{
   def main(args:Array[String]):Unit={
      val sparkConf = new SparkConf().setAppName("word-merge").se
tMaster("varn")
      val sc = new SparkContext(sparkConf)
      val A = sc.textFile("A.txt")
      val B = sc.textFile("B.txt")
      val AB = A.union(B)
      val distinct lines = AB.distinct()
      distinct lines.saveAsTextFile("hdfs://node1:8020/C.txt")
      sc.stop
   }
```

在上面的代码中,我通过(val型)A记录从A.txt中读取的内容、(val型)B记录从B.txt读取的内容,并通过union方法将二者进行合并,然后使用distinct()方法去除重复内容,最后使用saveAsTextFile方法写入结果。使用cat命令可以看到合并后的内容(如下图14所示),可以发现合并成功:

```
m root@frt-2020211616-0001:~
                                                                             0 2023-04-16 17:26 /C. txt/_SUCCESS
33 2023-04-16 17:26 /C. txt/part-00000
11 2023-04-16 17:26 /C. txt/part-00001
22 2023-04-16 17:26 /C. txt/part-00002
33 2023-04-16 17:26 /C. txt/part-00003
                         3 root supergroup
                         3 root supergroup
                         3 root supergroup
  rw-r--r-- 3 root supergroup 33 2023-04-16 17:26 /C.txt/part-00003 root@frt-2020211616-0001 ~]# hadoop fs -cat /C.txt/part-00000 (3/04/16 17:27:49 WARN util.NativeCodeLoader: Unable to load native-hadoop li
  classes where applicable
20170105 z
20170102 y
 20170103 x
[root@frt-2020211616-0001 ~]# hadoop fs -cat /C.txt/part-00001
23/04/16 17:27:55 WARN util.NativeCodeLoader: Unable to load native-hadoop li
  classes where applicable
20170106 z
  root@frt-2020211616-0001 ~]# hadoop fs -cat /C.txt/part-00002
3/04/16 17:28:00 WARN util.NativeCodeLoader: Unable to load native-hadoop li
 classes where applicable
[root@frt-2020211616-0001 ~]# hadoop fs -cat /C.txt/part-00003
23/04/16 17:28:05 WARN util.NativeCodeLoader: Unable to load native-hadoop li
classes where applicable
20170104 z
 20170101
 20170105 у
```

图 14: 文件合并结果(对应指导书图 53)

2.3. 使用 Spark SQL 读写数据库

在该部分实验中,我首先下载并安装了 MySQL, 然后启动 MySQL, 并通过指令查询 MySQL 运行状态如下图所示:

```
mysql-community-server. aarch64 0:8.0.32-1.el7

Dependency Installed:
libaio.aarch64 0:0.3.109-13.el7 mysql-community-client.aarchmysql-community-client-plugins.aarch64 0:8.0.32-1.el7 mysql-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-community-commun
```

图 15: MySQL 正常运行(对应指导书图 54)

使用 grep "password" /var/log/mysqld. log 可以查看 root 用户的密码,如下图 16 所示:

```
Toot@frt-2020211616-0001:~

Apr 16 19:31:48 frt-2020211616-0001 systemd[1]: Starting MySQL Server...

Apr 16 19:31:53 frt-2020211616-0001 systemd[1]: Started MySQL Server.

[root@frt-2020211616-0001 ]# grep "password" /var/log/mysqld.log
2023-04-16T11:31:50.389343Z 6 [Note] [MY-010454] [Server] A temporary password@localhost: wa*:dS=;01id
[root@frt-2020211010-0001]#
```

图 16: root 用户密码(对应指导书图 55)

接下来进入数据库,首先需要修改密码,然后创建 spark 数据库,在其中 创建 student 表,并通过 SQL 语句插入指定数据,结果如下所示:

mysql> ERROR 1 mysql>	ALTER U 819 (HY ALTER	SER 'root 000): You	'@'localh r passwor t'@'local	R USER root@frt-2020211616-0001 IDENTIFIED BY 'frtFR ost' IDENTIFIED BY 'frtFRT189260'; d does not satisfy the current policy requirements host' IDENTIFIED BY 'frtFRT189260.'; sec)
		database w affecte		ec)
Databas mysql>		ed table stu		nt(4), name char(20), gender char(4), age int(4)); nings (0.02 sec)
nysq1> Query 0	insert K, 1 ro	into stud w affecte	ent value d (0.00 s	s(1, 'Li', 'F', 23); ec)
		into stud w affecte		s(2, 'Wang', 'M', 24); ec)
nysql>	select	* from st	udent;	
id	name	gender	age	
1 2	Li Wang	F M	23 24	
2 rows	in set	(0.00 sec)	

图 17: 修改密码、创建数据库/表、插入数据(对应指导书图 56)

接下来我安装了 MySQL 数据库驱动程序,并进行解压和移动,然后使用指定命令启动(指定 MySQL 连接 jar 包的) spark shell,完成数据库读取,结果如下所示:

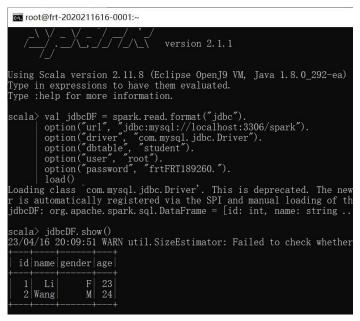


图 18: 对 MySQL 数据库的读取结果 (对应指导书图 57)

并且,在通过 JDBC 连接 MySQL 数据库时, option()方法中涉及到的参数含义如下表所示:

参数名称	参数的值	含义
分级 和	多数印加	百人

url	jdbc:mysql://localhost:3306/spark	数据库的连接地址
driver	com.mysql.jdbc.driver	数据库的 JDBC 驱动
dbtable	student	所要访问的表
user	root	用户名
password		用户密码

我编写了如下所示的向数据库中插入数据的代码:

```
package org.example
import org.apache.spark.rdd.RDD
import org.apache.spark.sql.{Row, SQLContext, types}
import org.apache.spark.sql.types.{IntegerType, StringType,
StructField, StructType}
import org.apache.spark.{SparkConf, SparkContext}
import java.sql.Struct
import java.util.Properties
class InsertStudent{
object InsertStudent{
 def main(args:Array[String]):Unit={
   val sparkConf = new SparkConf().setAppName("insert-student").se
tMaster("local")
   val sc = new SparkContext(sparkConf)
   val studentRDD = sc.parallelize(Array("3 Zhang M 26", "4 Liu M
27")).map( .split(" "))
   val schema = StructType(List(
     StructField("id", IntegerType, true),
     StructField("name", StringType, true),
     StructField("gender", StringType, true),
     StructField("age", IntegerType, true)))
   val rowRDD = studentRDD.map(p => Row(p(0).toInt, p(1).trim, p(2)
).trim, p(3).toInt))
   val studentDF = new SQLContext(sc).createDataFrame(rowRDD,
schema)
   val prop = new Properties()
   prop.put("user", "root")
   prop.put("password", "frtFRT189260.")
   prop.put("driver", "com.mysql.jdbc.Driver")
```

```
studentDF.write.mode("append").jdbc("jdbc:mysql://localhost:330
6/spark", "spark.student", prop)
}
```

在上面的代码中,studentRDD 定义了将要插入的 student 信息(即包括 Zhang 和 Liu 两个 student 信息),而 schema 定义了插入信息的格式,rowRDD 定义了 student 信息的"转换方式",然后通过 put 方法设置必要信息,最后通过 write 方法将数据写入到/spark 下的 student 表中。

将此代码按照和之前一样的思路打包为 jar 包,上传到 node1 并运行,可以看到如下图 19 所示的结果,可以看到插入成功:

ou can	turn of	f this fea		ompletion of table and column name o get a quicker startup with -A
	se change select *	from stud	dent;	
	name	gender	age	
id	ricano			
id 1	Li	 F	23	
id 1 2		F M	23 24	
1	Li		100000	

图 19: student 信息插入成功 (对应指导书图 60)

3. 实验问题与实验总结

本次实验中我也遇到了一些问题并进行了解决,现记录如下:

- (1) 使用 IDEA 创建项目时 Archetype 选择错误,如果按照实验指导书选择 org. scala 下的 scala-archetype-simple,则会导致模板与实验内容不 符,应当选择 net. alchim31 下的 scala-archetype-simple;
- (2) 编写去重功能时不知如何实现,通过研读指导书内容,结合相应函数功能,完成了代码编写。

在本次实验中,我在实验一、二、三的基础上安装了 Spark 和 MySQL 数据库驱动程序两个组件,并进行了相应的配置。我使用 scala 编写了计数功能代码、去重功能代码和数据库插入代码,调试排除了相应的错误,并打包为 jar 包上传到主节点上进行运行,得到了预期的正确结果。总的来说,我在本次实验中复习了理论知识、进行了工程实践,圆满完成了实验任务,收获颇丰!